

Vorlesung 14 Lineare & nicht-lineare Regression

Lineare Regression: wir haben das deterministische Modell

$$y = f_{\Theta}(x) = x^T \Theta' + \Theta_0, \quad x \in \mathbb{R}^D, y \in \mathbb{R}$$

wobei $\Theta' = (\Theta_1, \dots, \Theta_D)^T \in \mathbb{R}^D$, $\Theta_0 \in \mathbb{R}$.

Wir haben das stat. Modell

$$y \sim N(f_{\Theta}(x), \sigma^2) \quad \text{mit } \sigma^2 \text{ fest (= ein Hyperparameter)}$$

$$\text{D.h. } y = f_{\Theta}(x) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

Der MAP ist Θ_{MAP} mit $\Theta_{\text{MAP}} = \operatorname{argmax} P(\Theta | X, Y)$.

Wir wählen dazu den Prior $\Theta \sim N(\mu, \Sigma)$, $\mu \in \mathbb{R}^{D+1}$, $\Sigma \in \mathbb{R}^{(D+1) \times (D+1)}$ pos. def.

Theorem 14.1.

Sei $\mu \in \mathbb{R}^{D+1}$, $\Sigma \in \mathbb{R}^{(D+1) \times (D+1)}$ pos. definit. Für den Prior $\Theta \sim N(\mu, \Sigma)$ haben wir:

$$\Theta_{\text{MAP}} = (\Omega^T \Omega + \sigma^2 \Sigma^{-1})^{-1} (\Omega^T Y + \sigma^2 \Sigma^{-1} \mu).$$

mit

$$\Omega = \begin{pmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{pmatrix}^T \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}. \quad \text{und unter der Annahme, dass}$$

$\Omega^T \Omega + \sigma^2 \Sigma^{-1}$ invertierbar ist.

Beweis

Sei $\kappa(\Theta) = P(\Theta | X, Y)$ die Posteriori-Funktion.

$\Theta_{\text{MAP}} = \operatorname{argmax} \kappa(\Theta)$. Es gilt:

$$\kappa(\Theta) = P(\Theta | X, Y) = P(\Theta) \frac{P(Y | X, \Theta)}{P(Y | X)}.$$

nach dem Satz von Bayes. Sei $C := -\log P(Y | X)$.

Dann gilt:

$$\log \alpha(\theta) = \log P(\theta) + \log P(Y|X, \theta) + c.$$

und $P(\theta) = \frac{1}{\sqrt{(2\pi)^{D+1} \det(\Sigma)}} \exp(-\frac{1}{2} (\theta - \mu)^T \Sigma^{-1} (\theta - \mu))$

$$P(Y|X, \theta) = \prod_{i=1}^n P(y_i | x_i, \theta) = \prod_{i=1}^n P_{\theta}(y_i | x_i)$$

$$= \frac{1}{\sqrt{2\sigma^2}^n} \prod_{i=1}^n \exp(-\frac{1}{2\sigma^2} (y_i - f_{\theta}(x_i))^2)$$

$$= \frac{1}{\sqrt{2\sigma^2}^n} \exp(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2)$$

$$= \frac{1}{\sqrt{2\sigma^2}^n} \exp(-\frac{1}{2\sigma^2} \|\gamma - \Omega\theta\|^2)$$

Wir erhalten:

$$\log \alpha(\theta) = -\frac{1}{2} (\theta - \mu)^T \Sigma^{-1} (\theta - \mu) - \frac{1}{2\sigma^2} \|\gamma - \Omega\theta\|^2 + c'$$

mit c' unabh. von θ .

Um α zu maximieren sehen wir $\nabla_{\theta} \log \alpha(\theta) = 0$.

$$\nabla_{\theta} \log \alpha(\theta) = -\Sigma^{-1} (\theta - \mu) + \frac{1}{\sigma^2} \Omega^T (\gamma - \Omega\theta)$$

Mit $\nabla_{\theta} \log \alpha(\theta) = 0$ gilt:

$$\Sigma^{-1} (\theta - \mu) = + \frac{1}{\sigma^2} \Omega^T (\gamma - \Omega\theta).$$

$$\Rightarrow \Sigma^{-1} \theta - \Sigma^{-1} \mu = + \frac{1}{\sigma^2} \Omega^T \gamma - \frac{1}{\sigma^2} \Omega^T \Omega \theta$$

$$\Rightarrow \Sigma^{-1} \mu + \frac{1}{\sigma^2} \Omega^T \gamma = \left(\frac{1}{\sigma^2} \Omega^T \Omega + \Sigma^{-1} \right) \theta$$

$$\Rightarrow \theta = (\Omega^T \Omega + \sigma^2 \Sigma^{-1})^{-1} (\Omega^T \gamma + \sigma^2 \Sigma^{-1} \mu). \quad \square$$

In den Beweisen zu ERM, RR, MLE und MAP ist das Modell f_θ in Form der Zeilen von Ω eingegangen.

D.h., wir können einfach das lineare Modell zum nicht-linearen Modell erweitern, indem wir folgendes Modell definieren:

$$f_\theta(x) = \phi(x)^T \theta \quad \text{mit } \phi: \mathbb{R}^D \rightarrow \mathbb{R}^P \text{ nicht-linear.}$$

Die Feature-Matrix ist dann

$$\Omega = [\phi(x_1) \dots \phi(x_n)]^T.$$

Z.B.: • mit $\phi(x) = \begin{pmatrix} 1 \\ x \end{pmatrix} \in \mathbb{R}^{D+1}$ erhalten wir das lineare Modell

• für $D=1$ und $\phi(x) = (1, x, x^2, \dots, x^d)^T \in \mathbb{R}^{d+1}$ erhalten wir Polynomielle-Regression, da $f_\theta(x) = \sum_{i=0}^d \theta_i x^i$.

Die Formeln für θ_{ERM} , θ_{RR} , θ_{MLE} und θ_{MAP} gelten genauso im nicht-linearen Modell.

Jetzt wollen wir den Bayes'schen Ansatz wählen und die Verteilung $P(\theta | X, Y)$ direkt berechnen.

Theorem 14.2

Mit obigen Annahmen gilt:

$$(\theta | X, Y) \sim N(m, S),$$

mit

$$S = (\sigma^{-2} \Omega^T \Omega + \Sigma^{-1})^{-1} \quad \text{und} \quad m = S \left(\frac{1}{\sigma^2} \Omega^T Y + \Sigma^{-1} \mu \right)$$

Beweis Wir berechnen die Dichte $P(\Theta|X,Y)$.

Dazu berechnen wir $\log P(\Theta|X,Y)$.

$$\log P(\Theta|X,Y) = -\frac{1}{2} (\Theta - \mu)^T \Sigma^{-1} (\Theta - \mu) - \frac{1}{2\sigma^2} \|Y - \Omega\Theta\|^2 + c$$

mit c unabh. von Θ .

Wir setzen

$$Q = -(\Theta - \mu)^T \Sigma^{-1} (\Theta - \mu) - \frac{1}{\sigma^2} (Y - \Omega\Theta)^T (Y - \Omega\Theta)$$

so dass $P(\Theta|X,Y) = \exp(\frac{1}{2}Q + c)$

Es gilt:

$$Q = -\Theta^T \Sigma^{-1} \Theta + 2 \mu^T \Sigma^{-1} \Theta - \mu^T \Sigma^{-1} \mu - \frac{1}{\sigma^2} (Y^T Y - 2 Y^T \Omega \Theta + \Theta^T \Omega^T \Omega \Theta)$$

$$= -\Theta^T \Sigma^{-1} \Theta + 2 \mu^T \Sigma^{-1} \Theta + \frac{1}{\sigma^2} 2 Y^T \Omega \Theta - \frac{1}{\sigma^2} \Theta^T \Omega^T \Omega \Theta + c'$$

mit c' unabh. von Θ . Wir setzen

$$A = \frac{1}{\sigma^2} \Omega^T \Omega + \Sigma^{-1} = S.$$

$$a = \frac{1}{\sigma^2} \Omega^T Y + \Sigma^{-1} \mu$$

Dann:

$$\begin{aligned} Q &= \Theta^T A \Theta - 2 a^T \Theta + c' \\ &= (\Theta - b)^T A (\Theta - b) + c'' \end{aligned}$$

$$m = b = A^{-1} a = S^{-1} a = S^{-1} \left(\frac{1}{\sigma^2} \Omega^T Y + \Sigma^{-1} \mu \right).$$

□

Wir können den Bayes'schen Ansatz verwenden um

- Den Parameter Θ zu sampeln, oder
- Den Parameter "auszuinkrigieren".

Proposition 14.3 \swarrow Trainingsdaten $X = [x_1, \dots, x_n]^T \quad Y = [y_1, \dots, y_n]^T$

Gegeben seien Daten $(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^D \times \mathbb{R}$.

Sei $(x, y) \in \mathbb{R}^D \times \mathbb{R}$ ein weiterer Punkt. Die Verteilung von $(y | x, X, Y)$ ist.

$$(y | x, X, Y) \sim N(\phi(x)^T m, \phi(x)^T S \phi(x) + \sigma^2)$$

(für das nicht-lineare Modell bzgl. $\phi(x)$).

Beweisidee Verwende die Formel für Marginal-Density:

$$P(y | x, X, Y) = \int_{\mathbb{R}^P} P(y | x, X, Y, \theta) \cdot P(\theta | X, Y) d\theta$$

Die bisherige Diskussion handelt von nichtlinearen Funktionen $f_\theta: \mathbb{R}^D \rightarrow \mathbb{R}$.

Wir können die Theorie zu Funktion

$$f_\theta: \mathbb{R}^D \rightarrow \mathbb{R}^N$$

erweitern, indem wir

$$(x) \quad f_\theta(x) = \begin{bmatrix} \phi(x)^T \theta_1 \\ \vdots \\ \phi(x)^T \theta_N \end{bmatrix} \quad \text{mit } \theta = [\theta_1, \dots, \theta_N] \in \mathbb{R}^{P \times N}$$

$$\phi: \mathbb{R}^D \rightarrow \mathbb{R}^P$$

setzen und die Loss Funktion

$$\mathcal{L}(y, \hat{y}) = \|y - \hat{y}\|^2$$

bzw das stat. Modell

$$y|x \sim N(f_{\theta}(x), \sigma^2 \mathbf{1}_N).$$

Weil $\|y - \hat{y}\|^2 = \sum_{i=1}^N (y_i - \hat{y}_i)^2$, können wir jedes $\theta_i, i=1, \dots, N$ separat optimieren. D.h. für jeden Eintrag von f_{θ} in κ können wir die 1-dim. Schächer von oben verwenden.