

Vorlesung 15 Nicht-lineare Regression cont'd

Erinnerung: Wir haben ein Modell:

$$f_{\Theta}: \mathbb{R}^D \rightarrow \mathbb{R}^N$$

bzw. ein stat. Modell $P_{\Theta}(y(x))$.

Z.B.: $\left\{ \begin{array}{l} \text{das lineare Modell ist } f_{\Theta}(x) = (x^T \Theta_i' + \Theta_0^i)_{i=1}^N, \text{ wobei } \Theta_i = (\Theta_i', \Theta_0^i). \\ \text{das nicht-lin. Modell ist } f_{\Theta}(x) = (\phi(x)^T \Theta_i' + \Theta_0^i)_{i=1}^N \end{array} \right.$

Eine Erweiterung dieses Frameworks bieten neuronale Netze.

Definition 15.1

Sei $L > 0$ und $N_0, N_1, \dots, N_L > 0$. Für $1 \leq i \leq L$ sei

$$g_{\Theta_i}: \mathbb{R}^{N_i} \rightarrow \mathbb{R}^{N_{i-1}}$$


ein Modell für nicht-lineare Regression. Das def. Modell

$$f_{\Theta} = (g_{\Theta_1} \circ \dots \circ g_{\Theta_L}): \mathbb{R}^D \rightarrow \mathbb{R}^N,$$

wobei $N_0 = D$, $N_L = N$, heißt neuronales Netz von Tiefe L .

Die Funktion g_{Θ_i} wird iter Layer genannt.

Warum der Begriff "neuronales Netz"? Die Idee hinter Def. 15.1 ist, dass f_{Θ} die Struktur eines Gehirns nachbilden soll. Denn z.B. für $L=3$ und $N=1$, $D=4$, können wir ein neuronales Netz wie folgt visualisieren: ($N_1=2$, $N_2=4$)



Bemerkung Für Tiefe $L > 1$ können wir oft keine geschlossene Form für ERM, RR, MLE, MAP berechnen.
D.h. für die Parameterschätzung müssen wir Methoden aus der Optimierung verwenden.

Daher werden für die g_{θ_i} oft "einfache" Funktionen.

Eine Wahl, die oft getroffen wird ist

$$g_{\theta_i}(x) = \sigma(f_{\theta_i}(x))$$


- mit
- $f_{\theta_i}(x)$ ist ein nicht-lineares Regressionsmodell (meist sogar linear!)
 - σ ist eine nicht-lineare Activation-Funktion

Beispiele von solchen Activation-Funktionen:

1) ReLU-Funktion $\sigma(z) = \left(\max(0, z_i) \right)_{i=1}^k$, $z \in \mathbb{R}^k$

2) Sigmoid-Funktion $\sigma(z) = \left(\frac{1}{1 + e^{-z_i}} \right)_{i=1}^k$

3) Softmax $\sigma(z) = \left(\frac{\exp(z_i)}{\sum_{j=1}^k \exp(z_j)} \right)_{i=1}^k$



Wir können neuronale Netze für stat. Modelle verwenden:

Z.B., wenn die Output-Variablen $y \in \{c_1, \dots, c_L\}$ kategorisch ist.

Wir erhalten ein stat. Modell für $g(x)$ durch

$$P_{\theta}(y(x) = c_i) = (f_{\theta}(x))_i$$

mit f_{θ} ein NN, s.d. $f_{\theta}(x)_i \geq 0$ und $\sum_i f_{\theta}(x)_i = 1$.